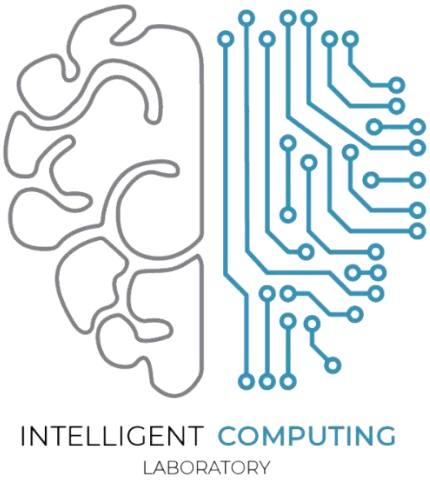
LAPORAN PRAKTIKUM

PEMBELAJARAN MESIN



NAMA : Tashfia Wahdah Fuady

NIM : 202431013

KELAS : C

DOSEN : Dr. Efy Yosrita, S.Si., M.Kom

NO.PC : 6

ASISTEN :

1. Muhammad Raka Ilham
2. Muhammad Hanif Nuruddin Jabbar
3. Muhammad Fachrydzi Irfansyah
4. Sharira Maharani

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2025/2026

A. EXPLORATORY DATA ANALYSIS (EDA)

Identitas Dataset

Nama Dataset: Food Delivery Dataset

Sumber: Kaggle – Food Delivery Dataset

Jumlah Data: 8.500 baris × 11 kolom.

Data ini merupakan dataset sintetis operasional pesan-antar makanan di Indonesia yang digunakan untuk menganalisis pola layanan seperti status pesanan, rating pelanggan, jarak pengiriman, dan kategori menu untuk keperluan pembersihan data, eksplorasi, serta pemodelan machine learning.

1. Import library (pandas, matplotlib).

```
[1]: #202431013_Tashfia Wahdah Fuady
     import pandas as pd
     import matplotlib.pyplot as plt
```

Langkah ini melakukan import library Pandas untuk mengolah data dan Matplotlib untuk membuat visualisasi. Kedua library tersebut digunakan pada proses analisis dataset.

2. Baca dataset (read_csv) dan tampilkan datanya.

```
[2]: #202431013_Tashfia Wahdah Fuady
df = pd.read_csv("fooddelivery.csv")
display(df.head())

print("Ukuran dataset:", df.shape)
```

	ID_Pesanan	Waktu_Transaksi	Kategori_Menu	Harga_Pesanan	Jarak_Kirim_KM	Waktu_Tunggu_Menit	Rating_Pelanggan	Ulasan_Teks	Status_Promo	Tingkat_Keluhan
0	ORD-2024-000001	2024-03-22 13:15:14	Kopi	9000	NaN	27	4.0	Sesuai pesanan	False	Tidak Ada
1	ORD-2024-000002	2024-01-14 17:05:37	Mie	21000	3.742238	37	NaN	NaN	False	Tidak Ada
2	ORD-2024-000003	2024-01-04 12:32:38	Martabak	33500	12.677149	49	NaN	NaN	True	Rendah
3	ORD-2024-000004	2024-01-26 22:34:26	Kopi	13500	2.338085	20	5.0	Mantap gan!	False	Tidak Ada
4	ORD-2024-000005	2024-03-16 11:48:51	Ayam	47500	0.949764	27	4.0	Top bgt kualitasnya	True	Rendah

```
Ukuran dataset: (8500, 11)
```

Langkah ini membaca dataset Food Delivery menggunakan fungsi read_csv(). Fungsi head() menampilkan lima baris pertama untuk melihat isi data, sedangkan shape menunjukkan bahwa dataset memiliki 8.500 baris dan 11 kolom.

3. Lihat informasi data (info()) dan deskripsi statistik (describe()).

3. Menampilkan informasi dataset

```
#202431013_Tashfia Wahdah Fuady
print("Informasi dataset:")
df.info()
```

```
Informasi dataset:
<class 'pandas.DataFrame'>
RangeIndex: 8500 entries, 0 to 8499
Data columns (total 11 columns):
 #   Column              Non-Null Count  Dtype
---  ------              --------------  -----
 0   ID_Pesanan          8500 non-null   str
 1   Waktu_Transaksi     8500 non-null   str
 2   Kategori_Menu       8500 non-null   str
 3   Harga_Pesanan       8500 non-null   int64
 4   Jarak_Kirim_KM      7905 non-null   float64
 5   Waktu_Tunggu_Menit  8500 non-null   int64
 6   Rating_Pelanggan    6800 non-null   float64
 7   Ulasan_Teks         6800 non-null   str
 8   Status_Promo        8500 non-null   bool
 9   Tingkat_Keluhan     8500 non-null   str
 10  Status_Pesanan      8500 non-null   str
dtypes: bool(1), float64(2), int64(2), str(6)
memory usage: 1.2 MB
```

4. Statistik deskriptif

```
#202431013_Tashfia Wahdah Fuady
print("Statistik deskriptif:")
display(df.describe())
```

Statistik deskriptif:

	Harga_Pesanan	Jarak_Kirim_KM	Waktu_Tunggu_Menit	Rating_Pelanggan
count	8.500000e+03	7905.000000	8500.000000	6800.000000
mean	1.134739e+05	3.095437	22.696941	4.175294
std	5.764418e+05	3.017151	13.488615	1.012719
min	0.000000e+00	0.500000	5.000000	1.000000
25%	1.900000e+04	0.900773	13.000000	4.000000
50%	2.900000e+04	2.141931	21.000000	4.000000
75%	4.500000e+04	4.156918	30.000000	5.000000
max	8.302000e+06	25.000000	112.000000	5.000000

Langkah ini digunakan untuk memeriksa struktur dataset, jumlah data per kolom, serta tipe data (teks, angka, dan boolean) untuk analisis lanjutan, sekaligus menampilkan ringkasan statistik atribut numerik seperti rata-

rata, standar deviasi, nilai minimum, dan maksimum yang menunjukkan bahwa harga pesanan memiliki rentang nilai yang cukup besar, sementara rating pelanggan berada pada rentang 1 sampai 5.

4. Pemeriksaan Struktur, Penanganan Missing Value, dan Analisis Nilai Unik pada Dataset

5. Memeriksa missing value

```
#202431013_Tashfia Wahdah Fuady
print("Jumlah missing value setiap kolom:")
print(df.isna().sum())
```

```
Jumlah missing value setiap kolom:
ID_Pesanan              0
Waktu_Transaksi         0
Kategori_Menu           0
Harga_Pesanan           0
Jarak_Kirim_KM        595
Waktu_Tunggu_Menit      0
Rating_Pelanggan     1700
Ulasan_Teks          1700
Status_Promo            0
Tingkat_Keluhan         0
Status_Pesanan          0
dtype: int64
```

6. Menampilkan nilai unik atribut kategorikal

```
#202431013_Tashfia Wahdah Fuady
kolom_kategori = ["Kategori_Menu", "Status_Promo",
    "Tingkat_Keluhan", "Status_Pesanan"]

for kolom in kolom_kategori:
    print(f"\nNilai unik pada kolom {kolom}:")
    print(df[kolom].unique())
```

```
Nilai unik pada kolom Kategori_Menu:
<ArrowStringArray>
['Kopi', 'Mie', 'Martabak', 'Ayam']
Length: 4, dtype: str

Nilai unik pada kolom Status_Promo:
[False  True]

Nilai unik pada kolom Tingkat_Keluhan:
<ArrowStringArray>
['Tidak Ada', 'Rendah', 'Tinggi']
Length: 3, dtype: str

Nilai unik pada kolom Status_Pesanan:
<ArrowStringArray>
['Selesai', 'Dibatalkan', 'Refund']
Length: 3, dtype: str
```

7. Menangani missing value

```
#202431013_Tashfia Wahdah Fuady
# Kolom numerik diisi menggunakan mean
# Kolom kategorikal diisi menggunakan modus
for kolom in df.columns:
    if df[kolom].isna().sum() > 0:
        if pd.api.types.is_numeric_dtype(df[kolom]):
            nilai_mean = df[kolom].mean()
            df[kolom] = df[kolom].fillna(nilai_mean)
        else:
            nilai_modus = df[kolom].mode()[0]
            df[kolom] = df[kolom].fillna(nilai_modus)

print("Missing value setelah penanganan:")
print(df.isna().sum())
```

```
Missing value setelah penanganan:
ID_Pesanan           0
Waktu_Transaksi      0
Kategori_Menu        0
Harga_Pesanan        0
Jarak_Kirim_KM       0
Waktu_Tunggu_Menit   0
Rating_Pelanggan     0
Ulasan_Teks          0
Status_Promo         0
Tingkat_Keluhan      0
Status_Pesanan       0
dtype: int64
```

Langkah ini dimulai dengan memeriksa jumlah data kosong pada setiap kolom menggunakan perintah isna().sum() yang menunjukkan adanya missing value pada tiga atribut (jarak pengiriman, rating pelanggan, dan ulasan teks) sehingga perlu ditangani, dilanjutkan dengan melihat isi unik dari kolom kategorik menggunakan perintah unique() untuk mengetahui variasi kategori seperti jenis menu, status promo, tingkat keluhan, dan status pesanan, serta diakhiri dengan menangani seluruh missing value tersebut menggunakan nilai rata-rata (mean) untuk atribut numerik dan modus untuk atribut kategorikal agar seluruh kolom bersih dan dataset menjadi lebih lengkap.

5. Hitung dan hapus data duplikat (duplicated().sum()), (drop_duplicates()).

8. Menghitung jumlah data duplikat

```
#202431013_Tashfia Wahdah Fuady
jumlah_duplikat = df.duplicated().sum()
print("Jumlah data duplikat:", jumlah_duplikat)
```

```
Jumlah data duplikat: 0
```

9. Menghapus data duplikat

```
#202431013_Tashfia Wahdah Fuady
df = df.drop_duplicates()

print("Informasi dataset setelah menghapus duplikat:")
df.info()
```

```
Informasi dataset setelah menghapus duplikat:
<class 'pandas.DataFrame'>
RangeIndex: 8500 entries, 0 to 8499
Data columns (total 11 columns):
 #   Column              Non-Null Count  Dtype
---  ------              --------------  -----
 0   ID_Pesanan          8500 non-null   str
 1   Waktu_Transaksi     8500 non-null   str
 2   Kategori_Menu       8500 non-null   str
 3   Harga_Pesanan       8500 non-null   int64
 4   Jarak_Kirim_KM      8500 non-null   float64
 5   Waktu_Tunggu_Menit  8500 non-null   int64
 6   Rating_Pelanggan    8500 non-null   float64
 7   Ulasan_Teks         8500 non-null   str
 8   Status_Promo        8500 non-null   bool
 9   Tingkat_Keluhan     8500 non-null   str
 10  Status_Pesanan      8500 non-null   str
dtypes: bool(1), float64(2), int64(2), str(6)
memory usage: 1.2 MB
```

Langkah ini dimulai dengan menghitung jumlah baris duplikat menggunakan fungsi duplicated().sum() yang menunjukkan bahwa tidak ada data duplikat pada dataset Food Delivery, sehingga saat proses penghapusan dilakukan menggunakan fungsi drop_duplicates() dan diperiksa kembali dengan info(), jumlah baris dataset tetap utuh sebanyak 8.500 data.

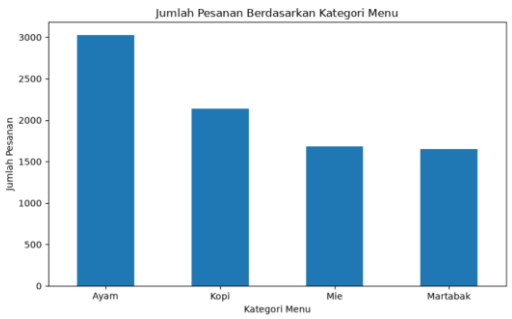
6. Visualisasi data

10. Visualisasi data kategori menu

```
[10]: #202431013_Tashfia Wahdah Fuady
jumlah_menu = df["Kategori_Menu"].value_counts()

plt.figure(figsize=(8, 5))
jumlah_menu.plot(kind="bar")

plt.title("Jumlah Pesanan Berdasarkan Kategori Menu")
plt.xlabel("Kategori Menu")
plt.ylabel("Jumlah Pesanan")
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()
```



Langkah ini membuat diagram batang untuk membandingkan jumlah pesanan pada setiap kategori menu. Hasilnya menunjukkan bahwa menu Ayam memiliki jumlah pesanan terbanyak, sedangkan Martabak memiliki jumlah pesanan paling sedikit.

B. SCRAPING

Pemeriksaan Robots.txt

Alamat robots.txt: https://id.wikipedia.org/robots.txt



Aturan yang berkaitan dengan halaman yang diambil

Halaman yang digunakan: https://id.wikipedia.org/wiki/Daftar_sekolah_dasar_negeri_di_Indonesia

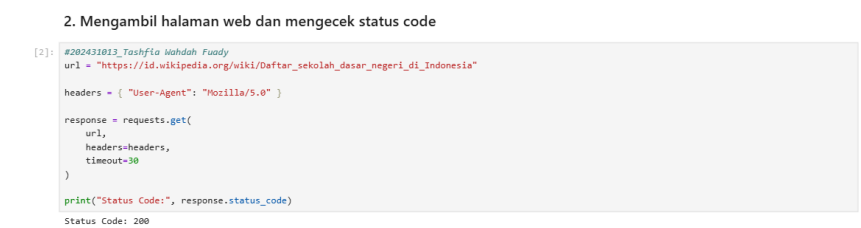
Aturan User-agent: * berlaku untuk semua web crawler, sedangkan Disallow menunjukkan halaman yang tidak boleh diakses. Halaman Daftar Sekolah Dasar Negeri di Indonesia dapat diambil karena alamatnya tidak termasuk dalam path yang dibatasi oleh aturan Disallow. Dengan demikian, halaman tersebut tidak dibatasi untuk proses scraping berdasarkan robots.txt, tetapi pengambilan data tetap harus mengikuti ketentuan penggunaan Wikipedia.

1. Import library.



Langkah ini dilakukan untuk mempersiapkan library yang dibutuhkan dalam proses web scraping. Library requests digunakan untuk mengambil halaman website, BeautifulSoup untuk membaca struktur HTML, csv untuk menyimpan data, pandas untuk mengolah dataset, dan re untuk membantu pencocokan teks menggunakan pola tertentu.

2. Mengakses website dan memeriksa status code.



Langkah ini digunakan untuk mengakses halaman Wikipedia menggunakan library requests. Hasil status code 200 menunjukkan bahwa halaman berhasil diakses dan server memberikan respons dengan baik. Dengan demikian, proses pengambilan data dapat dilanjutkan.

3. Membaca struktur HTML.

3. Mengubah HTML menjadi objek BeautifulSoup

```
[3]: #202431013_Tashfia Wahdah Fuady
soup = BeautifulSoup(response.text, "html.parser")

print("HTML berhasil diubah menjadi BeautifulSoup")
print("Judul halaman:", soup.title.get_text(strip=True))
```

```
HTML berhasil diubah menjadi BeautifulSoup
Judul halaman: Daftar sekolah dasar negeri di Indonesia - Wikipedia bahasa Indonesia, ensiklopecia bebas
```

Pada langkah ini, isi halaman website diubah menjadi objek BeautifulSoup agar struktur HTML lebih mudah dibaca dan ditelusuri. Judul halaman ditampilkan untuk memastikan bahwa website yang diakses sudah sesuai dengan sumber data yang digunakan.

4. Mengidentifikasi dan menghitung blok data.

4. Mencari seluruh blok data menggunakan find_all()

```
#202431013_Tashfia Wahdah Fuady
# Mencari seluruh tabel
tables = soup.find_all("table")

print("Jumlah seluruh tabel:", len(tables))

data_blocks = []

for table in tables:

    rows = table.find_all("tr")
    heading = table.find_previous("h2")
    province = "Tidak diketahui"

    if heading:
        headline = heading.find("span", class_="mw-headline")

        if headline:
            province = headline.get_text(strip=True)
```

```
    for row in rows:
        cells = row.find_all(["td", "th"],recursive=False)

        # Memastikan jumlah kolom mencukupi
        if len(cells) < 15:
            continue

        # Mengambil nomor urut
        nomor = cells[0].get_text(strip=True)

        # Mengambil nama kabupaten/kota
        wilayah = cells[1].get_text(" ", strip=True)

        # Memastikan baris merupakan data wilayah
        if nomor.isdigit() and re.match(r"^(Kab\.|Kabupaten|Kota)(\s|$)", wilayah):

            data_blocks.append({"province": province, "row": row})
print("Jumlah blok data kabupaten/kota:", len(data_blocks))
```

```
Jumlah seluruh tabel: 37
Jumlah blok data kabupaten/kota: 481
```

```
#202431013_Tashfia Wahdah Fuady
if len(data_blocks) >= 200:
    print("Jumlah data memenuhi syarat minimal 200 baris.")
else:
    print("Jumlah data belum memenuhi syarat minimal 200 baris.")
```

```
Jumlah data memenuhi syarat minimal 200 baris.
```

Langkah ini bertujuan untuk menemukan tabel yang berisi data jumlah sekolah pada setiap kabupaten/kota. Program mencari seluruh tabel HTML menggunakan find_all("table"), kemudian memeriksa setiap baris dan mengambil baris yang memiliki minimal 15 kolom serta nama wilayah yang sesuai. Hasilnya ditemukan 37 tabel pada halaman website dan sebanyak 481 blok data kabupaten/kota berhasil diidentifikasi. Jumlah tersebut sudah memenuhi ketentuan minimal 200 data.

5. Mengekstrak atribut data.

Pada langkah ini, data dari setiap baris tabel diekstrak berdasarkan kolom yang tersedia. Atribut yang diambil terdiri dari nama provinsi, kabupaten/kota, jumlah sekolah negeri dan swasta pada jenjang SD, SMP, SMA, dan SMK, serta total keseluruhan sekolah. Hasilnya terdapat 481 data dengan 15 atribut. Data tersebut nantinya digunakan sebagai dataset untuk proses pengolahan dan analisis lebih lanjut.

5. Mengambil setiap atribut dan menyimpannya ke list result

```
#202431013_Tashfia Wahdah Fuady
# Fungsi untuk membersihkan angka
def clean_number(text):

    # Menghapus tanda referensi seperti [1]
    text = re.sub(r"\[\d+\]", "", text)

    # Menghapus tanda titik, koma, dan karakter nonangka
    number = re.sub(r"\D", "", text)

    if number:
        return int(number)

    return None
```

```
#202431013_Tashfia Wahdah Fuady
result = []

for item in data_blocks:

    row = item["row"]
    province = item["province"]

    cells = row.find_all(["td", "th"], recursive=False)

    # Mengambil data kabupaten/kota
    wilayah = cells[1].get_text(" ", strip=True)
```

```
    # Mengambil atribut SD
    sd_negeri = clean_number(cells[2].get_text(strip=True))
    sd_swasta = clean_number(cells[3].get_text(strip=True))
    sd_jumlah = clean_number(cells[4].get_text(strip=True))

    # Mengambil atribut SMP
    smp_negeri = clean_number(cells[5].get_text(strip=True))
    smp_swasta = clean_number(cells[6].get_text(strip=True))
    smp_jumlah = clean_number(cells[7].get_text(strip=True))

    # Mengambil atribut SMA
    sma_negeri = clean_number(cells[8].get_text(strip=True))
    sma_swasta = clean_number(cells[9].get_text(strip=True))
    sma_jumlah = clean_number(cells[10].get_text(strip=True))

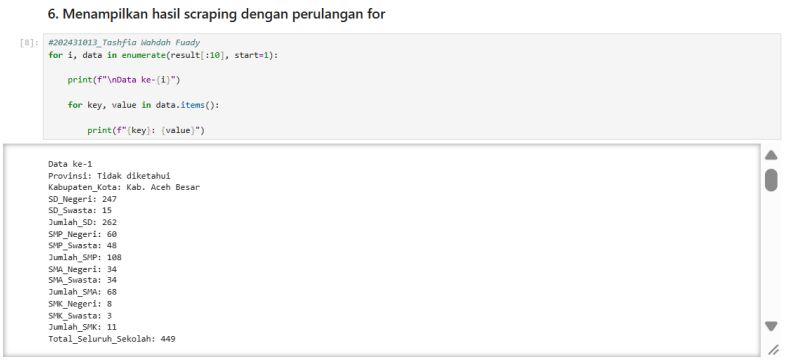
    # Mengambil atribut SMK
    smk_negeri = clean_number(cells[11].get_text(strip=True))
    smk_swasta = clean_number(cells[12].get_text(strip=True))
    smk_jumlah = clean_number(cells[13].get_text(strip=True))

    # Mengambil total seluruh sekolah
    total_sekolah = clean_number(
        cells[14].get_text(strip=True)
    )

    # Menyimpan hasil ke dalam list
    result.append({
        "Provinsi": province,
        "Kabupaten_Kota": wilayah,
        "SD_Negeri": sd_negeri,
        "SD_Swasta": sd_swasta,
        "Jumlah_SD": sd_jumlah,
        "SMP_Negeri": smp_negeri,
        "SMP_Swasta": smp_swasta,
        "Jumlah_SMP": smp_jumlah,
        "SMA_Negeri": sma_negeri,
        "SMA_Swasta": sma_swasta,
        "Jumlah_SMA": sma_jumlah,
        "SMK_Negeri": smk_negeri,
        "SMK_Swasta": smk_swasta,
        "Jumlah_SMK": smk_jumlah,
        "Total_Seluruh_Sekolah": total_sekolah
    })
print("Jumlah data berhasil diambil:", len(result))
```

```
Jumlah data berhasil diambil: 481
```

6. Menampilkan hasil ekstraksi.



Langkah ini digunakan untuk menampilkan hasil ekstraksi data dalam bentuk dictionary. Program menampilkan 10 data pertama agar isi setiap atribut dapat diperiksa sebelum disimpan. Dari hasil tersebut dapat diketahui bahwa data provinsi, kabupaten/kota, dan jumlah sekolah sudah berhasil diambil dari tabel website.

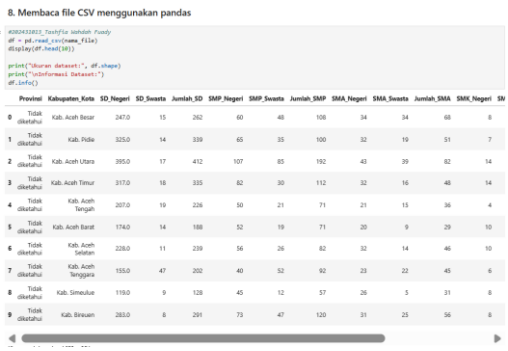
7. Menyimpan data ke CSV.

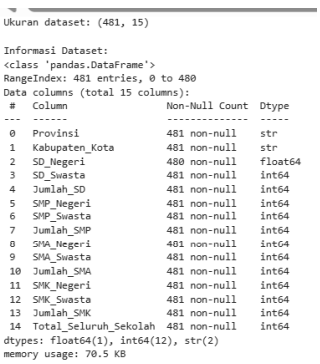




Pada langkah ini, seluruh data hasil scraping disimpan ke dalam file CSV menggunakan library csv. DictWriter digunakan untuk menuliskan data berdasarkan nama atribut, sedangkan writeheader() digunakan untuk menyimpan nama kolom. Setelah proses selesai, dataset berhasil disimpan dengan nama data_sekolah_indonesia.csv.

8. Membaca dataset menggunakan pandas.





Langkah ini dilakukan untuk membaca kembali file CSV menggunakan pandas. Fungsi head() menampilkan lima data pertama, sedangkan shape menunjukkan ukuran dataset. Hasilnya, dataset memiliki 481 baris dan 15 kolom, sehingga jumlah data yang diperoleh sudah sesuai dengan ketentuan praktikum.

9. Mengubah tipe data numerik dan menyimpan dataset akhir.

9. Memastikan tipe data numerik dan menyimpan dataset final

```
#202431013_Tashfia Wahdah Fuady
# Menentukan kolom numerik
kolom_numerik = [
    "SD_Negeri",
    "SD_Swasta",
    "Jumlah_SD",
    "SMP_Negeri",
    "SMP_Swasta",
    "Jumlah_SMP",
    "SMA_Negeri",
    "SMA_Swasta",
    "Jumlah_SMA",
    "SMK_Negeri",
    "SMK_Swasta",
    "Jumlah_SMK",
    "Total_Seluruh_Sekolah"
]

# Mengubah kolom menjadi tipe numerik
for kolom in kolom_numerik:

    df[kolom] = pd.to_numeric(
        df[kolom],
        errors="coerce"
    ).astype("Int64")

# Memastikan kolom kategori bertipe teks
df["Provinsi"] = df["Provinsi"].astype("string")
df["Kabupaten_Kota"] = df["Kabupaten_Kota"].astype("string")

# Menampilkan tipe data setelah konversi
print("Tipe Data Setelah Konversi:")
print(df.dtypes)
```

```
Tipe Data Setelah Konversi:
Provinsi                string
Kabupaten_Kota          string
SD_Negeri                Int64
SD_Swasta                Int64
Jumlah_SD                Int64
SMP_Negeri               Int64
SMP_Swasta               Int64
Jumlah_SMP               Int64
SMA_Negeri               Int64
SMA_Swasta               Int64
Jumlah_SMA               Int64
SMK_Negeri               Int64
SMK_Swasta               Int64
Jumlah_SMK               Int64
Total_Seluruh_Sekolah    Int64
dtype: object
```

```
#202431013_Tashfia Wahdah Fuady
df.to_csv(
    "data_sekolah_indonesia_final.csv",
    index=False,
    encoding="utf-8-sig"
)

print("Dataset final berhasil disimpan!")
```

```
Dataset final berhasil disimpan!
```

Langkah terakhir dilakukan untuk mengubah atribut jumlah sekolah menjadi tipe data numerik agar dapat digunakan dalam perhitungan dan analisis. Fungsi to_numeric() digunakan untuk mengubah nilai menjadi angka, sedangkan errors="coerce" akan mengubah nilai yang tidak dapat dibaca sebagai angka menjadi nilai kosong (NaN). Setelah itu, dataset disimpan kembali dengan nama data_sekolah_indonesia_final.csv.

C. REGRESI LINEAR

Judul dataset: Data Sekolah Indonesia

Sumber: Hasil praktikum Web Scraping Wikipedia

Nama file: data_sekolah_indonesia_final.csv

Jumlah data: 481 baris × 15 kolom

Penentuan Fitur dan Target

- Target (Y): Jumlah SD
- Fitur (X): Jumlah SMP, Jumlah SMA, dan Jumlah SMK.

Seluruh atribut berupa angka dan memiliki hubungan yang masuk akal karena jumlah sekolah pada berbagai jenjang pendidikan dapat menggambarkan kondisi fasilitas pendidikan di suatu wilayah.

1. Import library

1. Import Library

```
[1]: #202431013_Tashfia Wahdah Fuady
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
```

Langkah ini mengimpor beberapa library, yaitu NumPy dan Pandas untuk pengolahan data, Matplotlib untuk visualisasi, serta Scikit-learn untuk membagi data, membuat model regresi linear, dan mengevaluasi hasil prediksi.

2. Membaca dataset.

2. Membaca Dataset

```
[2]: #202431013_Tashfia Wahdah Fuady
df = pd.read_csv("data_sekolah_indonesia_final.csv")
display(df.head())

print("\nUkuran dataset:")
print(df.shape)
```

Kabupaten_Kota	SD_Negeri	SD_Swasta	Jumlah_SD	SMP_Negeri	SMP_Swasta	Jumlah_SMP	SMA_Negeri	SMA_Swasta	Jumlah_SMA	SMK_Negeri	SMK_Swasta	Jum
Kab. Aceh Besar	247.0	15	262	60	48	108	34	34	68	8	3	
Kab. Pidie	325.0	14	339	65	35	100	32	19	51	7	7	
Kab. Aceh Utara	395.0	17	412	107	85	192	43	39	82	14	10	
Kab. Aceh Timur	317.0	18	335	82	30	112	32	16	48	14	1	
Kab. Aceh Tengah	207.0	19	226	50	21	71	21	15	36	4	1	

Langkah ini membaca dataset sekolah Indonesia dari file CSV. Lima data pertama ditampilkan untuk melihat isi dataset, sedangkan df.shape digunakan untuk mengetahui jumlah baris dan kolom. Dataset tersebut terdiri dari 481 baris dan 15 kolom yang berisi informasi jumlah sekolah di berbagai kabupaten/kota.

3. Menghapus Data Kosong

```
#202431013_Tashfia Wahdah Fuady
kolom = ["Jumlah_SMP", "Jumlah_SMA", "Jumlah_SMK", "Jumlah_SD"]

df = df.dropna(subset=kolom)

print("Jumlah data setelah dropna:", len(df))
print("Jumlah data kosong:")
print(df[kolom].isnull().sum())
```

```
Jumlah data setelah dropna: 481
Jumlah data kosong:
Jumlah_SMP    0
Jumlah_SMA    0
Jumlah_SMK    0
Jumlah_SD     0
dtype: int64
```

4. Menentukan Fitur (X) dan Target (Y)

```
#202431013_Tashfia Wahdah Fuady
X = df[["Jumlah_SMP", "Jumlah_SMA", "Jumlah_SMK"]]
y = df["Jumlah_SD"]

print("Fitur (X):")
display(X.head())

print("\nTarget (Y):")
display(y.head())
```

Fitur (X):

	Jumlah_SMP	Jumlah_SMA	Jumlah_SMK
0	108	68	11
1	100	51	14
2	192	82	24
3	112	48	15
4	71	36	5

```
Target (Y):
0    262
1    339
2    412
3    335
4    226
Name: Jumlah_SD, dtype: int64
```

5. Membagi Data Latih dan Data Uji

```
#202431013_Tashfia Wahdah Fuady
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=0
)

print("Jumlah data latih:", len(X_train))
print("Jumlah data uji:", len(X_test))
```

```
Jumlah data latih: 384
Jumlah data uji: 97
```

6. Membuat Model Linear Regression

```
#202431013_Tashfia Wahdah Fuady
model = LinearRegression()

print("Model Linear Regression berhasil dibuat.")
```

```
Model Linear Regression berhasil dibuat.
```

7. Melatih Model

```
#202431013_Tashfia Wahdah Fuady
model.fit(X_train, y_train)

print("Model berhasil dilatih.")
```

```
Model berhasil dilatih.
```

8. Melakukan Prediksi Data Uji

```
#202431013_Tashfia Wahdah Fuady
y_pred = model.predict(X_test)

print("Hasil prediksi:")
print(y_pred[:10])
```

```
Hasil prediksi:
[ 177.11721035  170.99717721 1588.50543493  261.93085779  923.71214621
  932.21552399  154.82429849  158.3306157   126.18558771  135.77419409]
```

3. Menghapus Data Kosong

Langkah ini menghapus baris yang memiliki nilai kosong pada kolom Jumlah SMP, Jumlah SMA, Jumlah SMK, dan Jumlah SD. Penghapusan dilakukan agar data yang digunakan dalam proses pelatihan dan prediksi memiliki nilai yang lengkap.

4. Menentukan nilai x (fitur) dan y (target).

Langkah ini menentukan atribut yang digunakan dalam model regresi linear. Fitur (X) terdiri dari jumlah SMP, SMA, dan SMK, sedangkan target (Y) adalah jumlah SD yang akan diprediksi oleh model.

Kesesuaian dengan Syarat Dataset:

Pemilihan atribut tersebut telah memenuhi ketentuan praktikum karena target berupa satu atribut angka, yaitu Jumlah SD, sedangkan fitur terdiri dari atribut angka lainnya, yaitu Jumlah SMP, Jumlah SMA, dan Jumlah SMK. Hubungan antaratribut juga masuk akal karena jumlah sekolah pada berbagai jenjang pendidikan dapat menggambarkan perkembangan fasilitas pendidikan di suatu wilayah. Dengan demikian, jumlah SMP, SMA, dan SMK dapat digunakan sebagai fitur untuk memperkirakan jumlah SD di wilayah tersebut.

5. Membagi Data Training dan Testing

Langkah ini membagi dataset menjadi data training dan testing. Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk menguji kemampuan model dalam memprediksi data yang belum dipelajari. Parameter random_state=0 digunakan agar pembagian data tetap konsisten.

6. Buat model LinearRegression().

Langkah ini membuat model Linear Regression menggunakan library Scikit-learn. Model tersebut digunakan untuk mempelajari hubungan antara fitur berupa jumlah SMP, SMA, dan SMK dengan target berupa jumlah SD.

7. Melatih Model

Langkah ini melatih model menggunakan data training. Proses pelatihan bertujuan agar model dapat mempelajari pola hubungan antara fitur dan target sehingga dapat digunakan untuk melakukan prediksi.

8. Prediksi data uji (predict).

Langkah ini menggunakan model yang telah dilatih untuk memprediksi jumlah SD pada data testing. Hasil prediksi kemudian disimpan dalam variabel y_pred untuk dibandingkan dengan nilai aktual.

9. Evaluasi Model

```
#202431013_Tashfia Wahdah Fuady
mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print("Koefisien:", model.coef_)
print("Intercept:", model.intercept_)
print("MSE:", mse)
print("R2 Score:", r2)
```

```
Koefisien: [ 2.95656414 -2.5912003   1.43872181]
Intercept: 79.33165707312594
MSE: 12360.360707862996
R2 Score: 0.8717985518782051
```

10. Menampilkan Persamaan Regresi Linear

```
#202431013_Tashfia Wahdah Fuady
a = model.intercept_
b1, b2, b3 = model.coef_

print("Persamaan Regresi Linear:")
print(
    f"Y = {a:.4f} + ({b1:.4f} × X1) "
    f"+ ({b2:.4f} × X2) + ({b3:.4f} × X3)"
)
```

```
Persamaan Regresi Linear:
Y = 79.3317 + (2.9566 × X1) + (-2.5912 × X2) + (1.4387 × X3)
```

Visualisasi hasil regresi

```
#202431013_Tashfia Wahdah Fuady
plt.figure(figsize=(8, 5))

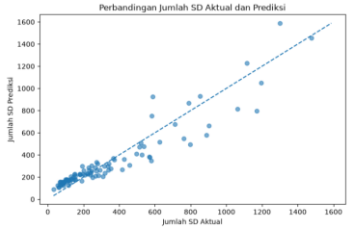
plt.scatter(y_test, y_pred, alpha=0.6)

plt.xlabel("Jumlah SD Aktual")
plt.ylabel("Jumlah SD Prediksi")
plt.title("Perbandingan Jumlah SD Aktual dan Prediksi")

# Garis pembanding
batas_min = min(y_test.min(), y_pred.min())
batas_max = max(y_test.max(), y_pred.max())

plt.plot(
    [batas_min, batas_max],
    [batas_min, batas_max],
    linestyle='--'
)

plt.show()
```



9. Evaluasi model

Langkah ini mengevaluasi hasil model menggunakan beberapa ukuran. Koefisien menunjukkan pengaruh setiap fitur terhadap hasil prediksi, sedangkan intercept merupakan nilai dasar model. MSE digunakan untuk mengukur rata-rata kuadrat kesalahan prediksi, sehingga nilai yang lebih kecil menunjukkan kesalahan yang lebih rendah. Sementara itu, R^2 Score menunjukkan seberapa besar variasi target dapat dijelaskan oleh model. Nilai R^2 yang semakin mendekati 1 umumnya menunjukkan kemampuan prediksi yang lebih baik.

10. Menampilkan Persamaan Regresi Linear

Langkah ini membentuk persamaan regresi linear berdasarkan hasil pelatihan model. Persamaan tersebut digunakan untuk menggambarkan hubungan antara fitur dan target, dengan X1 sebagai Jumlah SMP, X2 sebagai Jumlah SMA, dan X3 sebagai Jumlah SMK. Nilai koefisien menunjukkan perubahan prediksi jumlah SD berdasarkan perubahan setiap fitur, dengan fitur lainnya dianggap tetap.

11. Visualisasi Hasil Prediksi

Visualisasi ini digunakan untuk melihat kedekatan hasil prediksi dengan nilai aktual. Setiap titik menunjukkan perbandingan satu data, sedangkan garis putus-putus merupakan garis pembanding ideal. Semakin dekat titik-titik dengan garis tersebut, semakin mendekati hasil prediksi dengan nilai aktual.

D. DECISION TREE

Dataset dan Penentuan Fitur serta Target

- Dataset: Data Sekolah Indonesia
- Sumber: Hasil scraping Praktikum 2
- Nama file: data_sekolah_indonesia_final.csv
- Jumlah data: 481 baris × 15 kolom

Penentuan Atribut:

Jenis	Atribut	Keterangan
Target (Y)	Kategori_SD	Kategori jumlah SD (Rendah, Sedang, Tinggi)
Fitur (X1)	Jumlah_SMP	Jumlah SMP
Fitur (X2)	Jumlah_SMA	Jumlah SMA
Fitur (X3)	Jumlah_SMK	Jumlah SMK

Target Kategori_SD dibuat dari kolom Jumlah_SD dengan membagi data menjadi tiga kategori, yaitu Rendah, Sedang, dan Tinggi. Fitur yang digunakan merupakan atribut angka yang menggambarkan jumlah sekolah pada jenjang pendidikan lainnya. Hubungan tersebut digunakan untuk memprediksi kategori jumlah SD pada suatu wilayah.

1. Import library

1. Import Library

```
[1]: #202431013_Tashfia Wahdah Fuady
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import accuracy_score, classification_report
```

Langkah ini mengimpor library yang diperlukan untuk pengolahan data, visualisasi, pembuatan model Decision Tree, pengubahan kategori menjadi angka, serta evaluasi hasil prediksi.

2. Membaca dataset.

2. Membaca Dataset

```
[2]: #202431013_Tashfia Wahdah Fuady
df = pd.read_csv("data_sekolah_indonesia_final.csv")

display(df.head())
print("Ukuran dataset:", df.shape)
```

Kabupaten_Kota	SD_Negeri	SD_Swasta	Jumlah_SD	SMP_Negeri	SMP_Swasta	Jumlah_SMP	SMA_Negeri	SMA_Swasta	Jumlah_SMA	SMK_Negeri	SMK_Swasta	Ju
Kab. Aceh Besar	247.0	15	262	60	48	108	34	34	68	8	3	
Kab. Pidie	325.0	14	339	65	35	100	32	19	51	7	7	
Kab. Aceh Utara	395.0	17	412	107	85	192	43	39	82	14	10	
Kab. Aceh Timur	317.0	18	335	82	30	112	32	16	48	14	1	
Kab. Aceh Tengah	207.0	19	226	50	21	71	21	15	36	4	1	

```
Ukuran dataset: (481, 15)
```

Langkah ini membaca dataset hasil scraping dari file CSV. Lima data pertama ditampilkan untuk melihat isi dataset, sedangkan df.shape digunakan untuk mengetahui jumlah baris dan kolom. Dataset terdiri dari 481 baris dan 15 kolom.

3. Melihat informasi data (info()).

3. Melihat Informasi Data

```
[3]: #202431013_Tashfia Wahdah Fuady
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 481 entries, 0 to 480
Data columns (total 15 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   Provinsi              481 non-null    str
 1   Kabupaten_Kota        481 non-null    str
 2   SD_Negeri             480 non-null    float64
 3   SD_Swasta             481 non-null    int64
 4   Jumlah_SD             481 non-null    int64
 5   SMP_Negeri            481 non-null    int64
 6   SMP_Swasta            481 non-null    int64
 7   Jumlah_SMP            481 non-null    int64
 8   SMA_Negeri            481 non-null    int64
 9   SMA_Swasta            481 non-null    int64
 10  Jumlah_SMA            481 non-null    int64
 11  SMK_Negeri            481 non-null    int64
 12  SMK_Swasta            481 non-null    int64
 13  Jumlah_SMK            481 non-null    int64
 14  Total_Seluruh_Sekolah  481 non-null    int64
dtypes: float64(1), int64(12), str(2)
memory usage: 70.5 KB
```

5. Mengecek Data Kosong

```
[5]: #202431013_Tashfia Wahdah Fuady
print("Jumlah data kosong:")
print(df.isna().sum())
```

```
Jumlah data kosong:
Provinsi              0
Kabupaten_Kota        0
SD_Negeri             1
SD_Swasta             0
Jumlah_SD             0
SMP_Negeri            0
SMP_Swasta            0
Jumlah_SMP            0
SMA_Negeri            0
SMA_Swasta            0
Jumlah_SMA            0
SMK_Negeri            0
SMK_Swasta            0
Jumlah_SMK            0
Total_Seluruh_Sekolah 0
```

Langkah ini digunakan untuk mengetahui struktur dataset dan tipe data dari setiap atribut. Informasi tersebut membantu memastikan bahwa data telah terbaca dengan benar sebelum dilakukan pengolahan.

4. Melihat deskripsi statistik (describe()).

4. Melihat Deskripsi Statistik

```
[4]: #202431013_Tashfia Wahdah Fuady
     df.describe()
```

[4]:

	SD_Negeri	SD_Swasta	Jumlah_SD	SMP_Negeri	SMP_Swasta	Jumlah_SMP	SMA_Negeri	SMA_Swasta	Jumlah_SMA	SMK_Negeri	SMK_Swasta	Jumlah_SM
count	480.000000	481.000000	481.000000	481.000000	481.000000	481.000000	481.000000	481.000000	481.000000	481.000000	481.000000	481.000(
mean	264.118750	79.794179	340.744283	48.436590	63.952183	112.399168	14.646570	28.199584	42.846154	6.875260	20.767152	27.6424
std	238.613139	112.292240	320.669506	29.794236	99.106739	116.244331	8.823019	38.777862	43.275345	4.168962	35.466472	37.1693
min	17.000000	0.000000	23.000000	4.000000	0.000000	7.000000	1.000000	0.000000	1.000000	0.000000	0.000000	0.000(
25%	96.750000	15.000000	123.000000	27.000000	12.000000	44.000000	8.000000	7.000000	17.000000	4.000000	2.000000	8.000(
50%	183.500000	37.000000	228.000000	44.000000	27.000000	76.000000	13.000000	14.000000	29.000000	6.000000	7.000000	14.000(
75%	364.000000	93.000000	428.000000	65.000000	65.000000	135.000000	19.000000	29.000000	49.000000	9.000000	25.000000	30.000(
max	1545.000000	912.000000	2457.000000	174.000000	929.000000	1036.000000	67.000000	235.000000	284.000000	34.000000	350.000000	361.000(

Langkah ini digunakan untuk melihat gambaran umum nilai pada setiap atribut angka. Hasilnya dapat membantu memahami persebaran jumlah sekolah pada dataset.

5. Cek data kosong (isna().sum()).

Langkah ini memeriksa apakah terdapat nilai kosong pada dataset. Pemeriksaan dilakukan agar data yang digunakan dalam proses klasifikasi dapat dipastikan kelengkapannya.

6. Melihat Isi Unik Kolom Target

```
#202431013_Tashfia Wahdah Fuady
# Membuat kategori berdasarkan jumlah SD
df["Kategori_SD"] = pd.qcut(
    df["Jumlah_SD"],
    q=3,
    labels=["Rendah", "Sedang", "Tinggi"]
)

print("Kategori target:")
print(df["Kategori_SD"].unique())

print("\nJumlah data setiap kategori:")
print(df["Kategori_SD"].value_counts())

# Arti setiap kelas:
# Rendah = Wilayah dengan jumlah SD relatif sedikit
# Sedang = Wilayah dengan jumlah SD tingkat menengah
# Tinggi = Wilayah dengan jumlah SD relatif banyak
```

```
Kategori target:
['Sedang', 'Tinggi', 'Rendah']
Categories (3, str): ['Rendah' < 'Sedang' < 'Tinggi']

Jumlah data setiap kategori:
Kategori_SD
Rendah    161
Sedang    161
Tinggi    159
Name: count, dtype: int64
```

7. Memisahkan Fitur X dan Target Y

```
#202431013_Tashfia Wahdah Fuady
X = df[["Jumlah_SMP", "Jumlah_SMA", "Jumlah_SMK"]]
y = df["Kategori_SD"]

print("Fitur X:")
display(X.head())

print("\nTarget Y:")
display(y.head())
```

Fitur X:

	Jumlah_SMP	Jumlah_SMA	Jumlah_SMK
0	108	68	11
1	100	51	14
2	192	82	24
3	112	48	15
4	71	36	5

```
Target Y:
0    Sedang
1    Tinggi
2    Tinggi
3    Tinggi
4    Sedang
Name: Kategori_SD, dtype: category
Categories (3, str): ['Rendah' < 'Sedang' < 'Tinggi']
```

8. Mengubah X dan Y Menjadi Array Angka

```
#202431013_Tashfia Wahdah Fuady
le = LabelEncoder()

X = np.array(X, dtype=np.float64)
y = le.fit_transform(y)

y = np.array(y, dtype=np.int64)

print("Bentuk X:", X.shape)
print("Bentuk Y:", y.shape)

print("\nKode kategori:")
for i, kelas in enumerate(le.classes_):
    print(i, "=", kelas)
```

```
Bentuk X: (481, 3)
Bentuk Y: (481,)

Kode kategori:
0 = Rendah
1 = Sedang
2 = Tinggi
```

6. Melihat isi unik kolom target (unique())

Langkah ini digunakan untuk melihat kategori unik yang terdapat pada kolom target Kategori_SD. Hasilnya menunjukkan terdapat tiga kelas, yaitu Rendah, Sedang, dan Tinggi. Kategori tersebut menunjukkan tingkatan jumlah SD pada setiap wilayah, mulai dari jumlah yang relatif sedikit hingga banyak.

7. Memisahkan fitur x dan target y.

Langkah ini memisahkan atribut menjadi fitur (X) dan target (Y). Fitur terdiri dari jumlah SMP, SMA, dan SMK, sedangkan target merupakan kategori jumlah SD. Ketiga fitur digunakan sebagai dasar bagi model untuk memprediksi kategori target.

8. Mengubah X dan Y Menjadi Array Angka

Langkah ini mengubah fitur X menjadi array bertipe float64 dan target Y menjadi angka bertipe int64 menggunakan LabelEncoder. Hasilnya menunjukkan bahwa X memiliki 481 baris dan 3 fitur, sedangkan Y memiliki 481 data target. Setiap angka mewakili kategori tertentu, yaitu 0 untuk Rendah, 1 untuk Sedang, dan 2 untuk Tinggi.

9. Membagi Data Training dan Testing

```
#202431013_Tashfia Wahdah Fuady
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.3,
    random_state=0
)

print("Jumlah data latih:", len(X_train))
print("Jumlah data uji:", len(X_test))
```

```
Jumlah data latih: 336
Jumlah data uji: 145
```

10. Membuat dan Melatih Model Decision Tree

```
#202431013_Tashfia Wahdah Fuady
model = DecisionTreeClassifier(max_depth=3)

model.fit(X_train, y_train)

print("Model Decision Tree berhasil dilatih.")
```

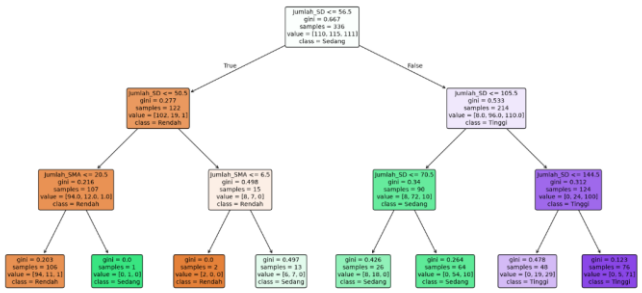
```
Model Decision Tree berhasil dilatih.
```

11. Visualisasi Pohon Keputusan

```
#202431013_Tashfia Wahdah Fuady
plt.figure(figsize=(20, 10))

plot_tree(
    model,
    feature_names=["Jumlah_SD", "Jumlah_SMP", "Jumlah_SMA", "Jumlah_SMK"],
    class_names=le.classes_,
    filled=True,
    rounded=True
)

plt.show()
```



9. Membagi Data Training dan Testing

Langkah ini membagi dataset menjadi data training dan testing dengan perbandingan 70% dan 30%. Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk menguji kemampuan model dalam memprediksi kategori. Parameter random_state=0 digunakan agar pembagian data tetap konsisten.

10. Membuat model DecisionTreeClassifier() dan latih (fit).

Langkah ini membuat model Decision Tree Classifier dengan kedalaman maksimum 3, kemudian melatihnya menggunakan data training. Pembatasan kedalaman dilakukan agar struktur pohon tidak terlalu kompleks dan lebih mudah divisualisasikan.

11. Visualisasi pohon (tree.plot_tree).

Langkah ini menampilkan struktur pohon keputusan yang telah dibentuk oleh model. Setiap percabangan menunjukkan aturan pemisahan data berdasarkan nilai fitur, sedangkan bagian akhir pohon menunjukkan kategori hasil klasifikasi. Visualisasi ini membantu memahami proses model dalam menentukan kategori jumlah SD.

12. Menguji dengan Satu Data Baru

```
#202431013_Tashfia Wahdah Fuady
data_baru = np.array([[50, 30, 20]], dtype=np.float64)

prediksi = model.predict(data_baru)

print("Hasil prediksi:", le.inverse_transform(prediksi)[0])
```

```
Hasil prediksi: Rendah
```

13. Menghitung Akurasi

```
#202431013_Tashfia Wahdah Fuady
y_pred = model.predict(X_test)

akurasi = accuracy_score(y_test, y_pred)

print("Akurasi Model:", akurasi)
print("Akurasi dalam persen:", akurasi * 100, "%")
```

```
Akurasi Model: 0.8137931034482758
Akurasi dalam persen: 81.37931034482759 %
```

14. Menampilkan Classification Report

```
#202431013_Tashfia Wahdah Fuady
print("Classification Report:")
print(classification_report(
    y_test,
    y_pred,
    labels=np.arange(len(le.classes_)),
    target_names=le.classes_,
    zero_division=0
))
```

```
Classification Report:
              precision    recall  f1-score   support

      Rendah       0.89      0.82      0.86        51
      Sedang       0.68      0.78      0.73        46
      Tinggi       0.89      0.83      0.86        48

    accuracy                           0.81       145
   macro avg       0.82      0.81      0.81       145
weighted avg       0.82      0.81      0.82       145
```

12. Uji dengan 1 data baru (predict).

Langkah ini menguji model menggunakan satu data baru yang terdiri dari jumlah SMP sebanyak 50, SMA sebanyak 30, dan SMK sebanyak 20. Model kemudian memprediksi kategori jumlah SD berdasarkan pola yang telah dipelajari selama proses training.

13. Hitung akurasi (accuracy_score).

Langkah ini menghitung tingkat ketepatan model dalam memprediksi kategori jumlah SD pada data testing. Hasil akurasi sebesar 81,38% menunjukkan bahwa sebagian besar data pengujian berhasil diklasifikasikan dengan benar oleh model.

14. Tampilkan classification_report.

Langkah ini menampilkan hasil evaluasi model berdasarkan precision, recall, f1-score, dan support. Kategori Rendah dan Tinggi memperoleh nilai F1-score sebesar 0,86, sedangkan kategori Sedang memperoleh 0,73. Hasil tersebut menunjukkan bahwa model lebih baik dalam mengenali kategori Rendah dan Tinggi dibandingkan kategori Sedang.

E. NAÏVE BAYES

Identitas Dataset

Nama Dataset: Bali Destination Google Maps Web Scrap

Sumber: [Kaggle – Bali Destination Google Maps Web Scrap]

Jumlah Data Awal: 761 baris × 8 kolom.

1. Import library (pandas, numpy, matplotlib, seaborn).

```
[1]: #202431013_Tashfia Wahdah Fuady
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import confusion_matrix, classification_report
```

Langkah ini mengimpor library Pandas dan NumPy untuk pengolahan data, Matplotlib dan Seaborn untuk visualisasi, serta Scikit-learn untuk encoding, pembagian data, pembuatan model, dan evaluasi Naïve Bayes.

2. Baca dataset dan tampilkan datanya (head()).

2. Membaca dataset

```
[2]: #202431013_Tashfia Wahdah Fuady
df = pd.read_csv("tempat_wisata_bali.csv")
display(df.head())

print("Ukuran dataset:", df.shape)
```

	nama	kategori	kabupaten_kota	rating	preferensi	link	latitude	longitude
0	Taman Mumbul Sangeh	Alam	Kabupaten Badung	4.6	Wisata Alam	https://www.google.com/maps/place/Taman+Mumbul...	-8.483959	115.2122881
1	Sangeh Monkey Forest	Alam	Kabupaten Badung	4.6	Wisata Alam	https://www.google.com/maps/place/Sangeh+Monke...	-8.4817743	115.2067391
2	Objek Wisata Sangeh	Umum	Kabupaten Badung	4.6	Wisata Umum	https://www.google.com/maps/place/Objek+Wisata...	-8.4815663	115.2065458
3	Satria Gatotkaca Park	Umum	Kabupaten Badung	4.6	Wisata Umum	https://www.google.com/maps/place/Satria+Gatot...	-8.7443882	115.1788673
4	Desa Wisata Penarungan	Umum	Kabupaten Badung	5.0	Wisata Umum	https://www.google.com/maps/place/Desa+Wisata+...	-8.5396366	115.198893

```
Ukuran dataset: (761, 8)
```

Langkah ini membaca dataset tempat wisata Bali dan menampilkan lima baris pertama. Hasilnya menunjukkan bahwa dataset memiliki 761 data tempat wisata dengan delapan atribut.

3. Lihat informasi data (info()) dan deskripsi statistik (describe()).

3. Melihat informasi dataset

```
#202431013_Tashfia Wahdah Fuady
print("Informasi dataset:")
df.info()

print("\nDeskripsi statistik:")
display(df.describe())
```

```
Informasi dataset:
<class 'pandas.DataFrame'>
RangeIndex: 761 entries, 0 to 760
Data columns (total 8 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   nama            761 non-null    str
 1   kategori        761 non-null    str
 2   kabupaten_kota  761 non-null    str
 3   rating          751 non-null    float64
 4   preferensi      761 non-null    str
 5   link            761 non-null    str
 6   latitude        761 non-null    str
 7   longitude       761 non-null    str
dtypes: float64(1), str(7)
memory usage: 271.6 KB
```

Deskripsi statistik:

	rating
count	751.000000
mean	4.536884
std	0.263839
min	3.000000
25%	4.400000
50%	4.600000
75%	4.700000
max	5.000000

Mengubah koordinat menjadi numerik

```
#202431013_Tashfia Wahdah Fuady
for kolom in ["latitude", "longitude"]:
    df[kolom] = pd.to_numeric(
        df[kolom].astype(str).str.replace(",", ".", regex=False),
        errors="coerce")

df["rating"] = pd.to_numeric(df["rating"], errors="coerce")
```

Menghapus data duplikat

```
#202431013_Tashfia Wahdah Fuady
df = df.drop_duplicates().copy()
print("Ukuran dataset setelah menghapus duplikat:", df.shape)
```

```
Ukuran dataset setelah menghapus duplikat: (758, 8)
```

Mengisi missing value fitur numerik dengan median

```
#202431013_Tashfia Wahdah Fuady
fitur_numerik_awal = ["rating", "latitude", "longitude"]

for kolom in fitur_numerik_awal:
    df[kolom] = df[kolom].fillna(df[kolom].median())
```

Langkah ini digunakan untuk melihat informasi dan statistik dataset. Hasil pemeriksaan menunjukkan bahwa koordinat masih terbaca sebagai teks dan terdapat 10 missing value pada rating. Oleh karena itu, koordinat dikonversi menjadi numerik, tiga data duplikat dihapus, dan missing value pada fitur numerik diisi menggunakan median.

4. Memisahkan fitur numerik
5. Memisahkan fitur kategorikal

4. Memisahkan fitur numerik

```
#202431013_Tashfia Wahdah Fuady
fitur_numerik = df.select_dtypes(include=["int64", "float64"]).columns.tolist()

print("Jumlah fitur numerik:", len(fitur_numerik))
print("Daftar fitur numerik:")
print(fitur_numerik)
```

```
Jumlah fitur numerik: 3
Daftar fitur numerik:
['rating', 'latitude', 'longitude']
```

5. Memisahkan fitur kategorikal

```
#202431013_Tashfia Wahdah Fuady
fitur_kategorikal = df.select_dtypes(include=["object", "category"]).columns.tolist()

print("Jumlah fitur kategorikal:", len(fitur_kategorikal))
print("Daftar fitur kategorikal:")
print(fitur_kategorikal)
```

```
Jumlah fitur kategorikal: 5
Daftar fitur kategorikal:
['nama', 'kategori', 'kabupaten_kota', 'preferensi', 'link']
```

Langkah ini dilakukan dengan memisahkan atribut menjadi tiga fitur numerik yaitu rating, latitude, dan longitude yang dapat digunakan sebagai dasar dalam proses klasifikasi, serta memisahkan lima fitur yang berisi data berbentuk teks atau kategori yang nantinya dapat diubah menjadi representasi angka menggunakan teknik LabelEncoder.

6. Menampilkan isi unik tiap fitur kategorikal.

6. Menampilkan nilai unik setiap fitur kategorikal

```
[9]: #202431013_Tashfia Wahdah Fuady
     for kolom in fitur_kategorikal:
         print(f"\nNilai unik pada kolom {kolom}:")
         print(df[kolom].unique())
```

```
Nilai unik pada kolom nama:
<ArrowStringArray>
[                         'Taman Mumbul Sangeh',
                        'Sangeh Monkey Forest',
                         'Objek Wisata Sangeh',
                       'Satria Gatotkaca Park',
                     'Desa Wisata Penarungan',
                                'Waterblow',
                           'Pantai Mengening',
                 'Kawasan Pariwisata Nusa Dua',
                 'Gunung Payung Cultural Park',
     'Taman Anyar - Traditional Balinese House',
 ...
     'TAMAN INSPIRASI dan WARUNG MUNTIG SIOKAN',
                     'Agung Jagatnatha Temple',
                           'Pantai Bangsal',
                         'Museum Le Mayeur',
```

Langkah ini menampilkan variasi nilai pada setiap atribut kategorikal. Hasilnya menunjukkan bahwa target kategori memiliki empat kelas tempat wisata, sedangkan atribut kabupaten/kota memiliki sembilan wilayah berbeda di Bali.

7. Ubah fitur kategorikal menjadi angka dengan LabelEncoder, lalu tampilkan hasilnya (head()).

7. Mengubah fitur kategorikal menjadi angka menggunakan LabelEncoder

```
[10]: #202431013_Tashfia Wahdah Fuady
label_encoders = {}

for kolom in fitur_kategorikal:
    encoder = LabelEncoder()
    df[kolom + "_encoded"] = encoder.fit_transform(df[kolom].astype(str))
    label_encoders[kolom] = encoder

print("\nHasil encoding:")
display(df.head())
```

Hasil encoding:

	nama	kategori	kabupaten_kota	rating	preferensi	link	latitude	longitude	nama_encoded	kategori_encode
0	Taman Mumbul Sangeh	Alam	Kabupaten Badung	4.6	Wisata Alam	https://www.google.com/maps/place/Taman+Mumbul...	-8.483959	115.212288	613	
1	Sangeh Monkey Forest	Alam	Kabupaten Badung	4.6	Wisata Alam	https://www.google.com/maps/place/Sangeh+Monke...	-8.481774	115.206739	555	
2	Objek Wisata Sangeh	Umum	Kabupaten Badung	4.6	Wisata Umum	https://www.google.com/maps/place/Objek+Wisata...	-8.481566	115.206546	351	
3	Satria Gatotkaca Park	Umum	Kabupaten Badung	4.6	Wisata Umum	https://www.google.com/maps/place/Satria+Gatot...	-8.744388	115.178867	562	
4	Desa Wisata Penarungan	Umum	Kabupaten Badung	5.0	Wisata Umum	https://www.google.com/maps/place/Desa+Wisata+...	-8.539637	115.198893	169	

Langkah ini mengubah data kategorikal menjadi angka menggunakan LabelEncoder agar dapat diproses oleh algoritma sehingga menghasilkan kolom terenkode seperti nama_encoded, kategori_encoded, kabupaten_kota_encoded, preferensi_encoded, dan link_encoded di mana pemetaan target kategori menghasilkan kode numerik tertentu seperti Alam menjadi 0, Budaya menjadi 1, Rekreasi menjadi 2, dan Umum menjadi 3 yang nantinya digunakan sebagai target dalam proses klasifikasi.

8. Memisahkan fitur X dan target Y

```
#202431013_Tashfia Wahdah Fuady
# Nama, link, dan preferensi tidak digunakan sebagai prediktor.
fitur_X = ["rating","latitude","longitude","kabupaten_kota_encoded"]

X = df[fitur_X]
y = df["kategori_encoded"]

print("Fitur X:")
display(X.head())

print("\nTarget Y:")
display(y.head())
```

Fitur X:

	rating	latitude	longitude	kabupaten_kota_encoded
0	4.6	-8.483959	115.212288	0
1	4.6	-8.481774	115.206739	0
2	4.6	-8.481566	115.206546	0
3	4.6	-8.744388	115.178867	0
4	5.0	-8.539637	115.198893	0

```
Target Y:
0    0
1    0
2    3
3    3
4    3
Name: kategori_encoded, dtype: int64
```

9. Membagi data latih dan data uji

```
#202431013_Tashfia Wahdah Fuady
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=0)

print("Jumlah data latih:", len(X_train))
print("Jumlah data uji:", len(X_test))
```

```
Jumlah data latih: 568
Jumlah data uji: 190
```

10. Membuat dan melatih model GaussianNB

```
#202431013_Tashfia Wahdah Fuady
model = GaussianNB()
model.fit(X_train, y_train)

print("Model Gaussian Naive Bayes berhasil dilatih.")
```

```
Model Gaussian Naive Bayes berhasil dilatih.
```

11. Melakukan prediksi data latih dan data uji

```
#202431013_Tashfia Wahdah Fuady
y_pred_train = model.predict(X_train)
y_pred_test = model.predict(X_test)

print("Prediksi data training:")
print(y_pred_train[:10])

print("\nPrediksi data testing:")
print(y_pred_test[:10])
```

```
Prediksi data training:
[0 2 3 2 3 0 0 0 0 0]

Prediksi data testing:
[3 3 0 0 3 2 0 0 0 3]
```

8. Memisahkan fitur x dan target y.

Langkah ini memisahkan data menjadi fitur X yang terdiri dari rating, latitude, longitude, dan kabupaten_kota_encoded serta target Y berupa kategori_encoded dengan empat kelas (0, 1, 2, dan 3), di mana kolom preferensi tidak digunakan sebagai fitur karena isinya mirip dengan kategori wisata sehingga berisiko menyebabkan kebocoran informasi target.

9. Bagi data latih dan uji: test_size = 0.25, random_state = 0.

Langkah ini membagi dataset menjadi data latih dan data uji dengan perbandingan 75% dan 25%. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengukur kemampuan model dalam memprediksi data yang belum dipelajari.

10. Buat model GaussianNB() dan latih (fit).

Langkah ini membuat model menggunakan algoritma Gaussian Naïve Bayes dan melatihnya dengan data training. Model mempelajari pola dari fitur yang diberikan untuk memperkirakan kategori tempat wisata.

11. Prediksi data latih dan data uji (predict).

Langkah ini menggunakan model yang telah dilatih untuk memprediksi kategori pada data training dan testing. Hasilnya berupa angka yang mewakili masing-masing kategori wisata, yaitu Alam, Budaya, Rekreasi, dan Umum.





12. Evaluasi data Training.

Langkah ini dilakukan untuk mengevaluasi kemampuan model dalam memprediksi data training. confusion_matrix() digunakan untuk membandingkan hasil prediksi dengan label sebenarnya, sedangkan classification_report() menampilkan nilai precision, recall, f1-score, dan accuracy untuk setiap kategori. Hasil confusion matrix juga divisualisasikan menggunakan heatmap agar jumlah prediksi benar dan salah pada setiap kategori lebih mudah diamati.

13. Evaluasi data Testing.

Langkah ini dilakukan untuk mengukur kemampuan model dalam memprediksi data testing yang belum digunakan selama proses pelatihan. Confusion matrix menunjukkan perbandingan antara hasil prediksi dan kategori sebenarnya, sedangkan classification report menampilkan nilai precision, recall, f1-score, dan accuracy. Hasilnya divisualisasikan menggunakan heatmap untuk mempermudah analisis ketepatan prediksi model pada data baru.

14. Uji dengan 1 data baru (predict), lalu tampilkan hasil prediksinya.



Langkah ini menguji model menggunakan satu data baru dengan rating 4,5 dan koordinat yang telah ditentukan. Hasil prediksi menunjukkan bahwa data tersebut diklasifikasikan sebagai kategori Alam oleh model Gaussian Naïve Bayes.